

Standortbestimmung mittels ADS-B Sensordaten und maschinellem Lernen

David Fuhry¹

Universität Leipzig
Machine Learning Group
Leipzig, Germany
`df15nocu@studserv.uni-leipzig.de`

Zusammenfassung. Es wird ein Verfahren vorgestellt um mit ADS-B Sensordaten den Breitengrad eines Flugzeugstandortes zu ermitteln. Zum Einsatz kommen Regressionsverfahren des maschinellen Lernens. Der Breitengrad kann mit einer mittleren Genauigkeit von unter 20km bestimmt werden. Für eine produktive Anwendung in der Luftraumüberwachung müssen die eingesetzten Verfahren weiter optimiert werden.

Schlüsselwörter: Maschinelles Lernen, ADS-B, Regression, Positionsbestimmung

1 Einleitung

Verschwörungstheorien sind aktuell häufig im Zentrum der Aufmerksamkeit. Während dieser, aktuelle Aufmerksamkeitsschub inhaltlich auf die aktuelle Pandemie zurückzuführen ist, bietet das Internet und die Verbreitung sozialer Medien das technische Fundament für die schnelle Verbreitung wie sie aktuell stattfindet. Das zunehmende Vernetzung solchen Theorien vorschub leistet ist keine neue Entwicklung, sondern wird schon länger im wissenschaftlichen Diskurs über Verschwörungstheorien beobachtet. Die wissenschaftliche Auseinandersetzung mit Verschwörungstheorien ist trotz des verstärkten Interesses in der jüngsten Vergangenheit bis heute eher verhalten.

Die komplexe Natur von Verschwörungstheorien stellt die wissenschaftliche Auseinandersetzung mit ihnen vor einige Grundlegende Probleme. Das offensichtlichste davon ist sicherlich die Frage was überhaupt eine Verschwörungstheorie ist. Hierzu existiert vor allem in der Wissenssoziologie eine Vielzahl von Literatur, ein klarer Konsens über eine Definition von Verschwörungstheorien fehlt jedoch bislang. Insbesondere für die Arbeit mit Beiträgen aus sozialen Netzen und anderen Online-Quellen schließt sich die Frage an, wie Verschwörungstheoretische Beiträge zuverlässig identifiziert werden können. Der Nutzen solcher Techniken nicht nur innerhalb der Wissenschaft ist naheliegend, so versuchen auch die Betreiber von sozialen Netzwerken daran verschwörungstheoretische Inhalte automatisiert zu erkennen (Beispiel google/youztube). In der Forschung wird dieses Problem klassischerweise mit der Hilfe einer Vielzahl von Hilfskräften gelöst, die die Daten manuell bearbeiten. (Studie mit codierern)

Diese Arbeit stellt einen Ansatz vor, dieses Problem mit Technologien der automatischen Sprachverarbeitung und des maschinellen Lernens zu lösen. Primär werden dabei stilistische Merkmale der untersuchten Texte genutzt und nur sekundär inhaltliche Informationen wie das Verwenden von Schlüsselwörtern etc. Durch das Verwenden solcher Technologien kann zum einen der Ressourcenaufwand drastisch reduziert werden, aber auch die Abhängigkeit von komplexen und damit fehleranfälligen Kriterien für die Klassifizierung lässt sich so umgehen. Auch ist der hier vorgestellte Ansatz durch den Fokus auf stilistische Merkmale verhältnismäßig robust gegenüber neuen inhaltlichen Entwicklungen der Verschwörungstheorien und somit potentiell zukunftssicherer als vergleichbare Ansätze.

Im folgenden soll zunächst ein kurzer Abriss über den aktuellen Stand der wissenschaftlichen Auseinandersetzung mit Verschwörungstheorien allgemein, sowie der Forschung zu linguistischen Merkmalen im speziellen, gegeben werden. Anschließend soll kurz auf die verwendeten Technologien sowie die Datengrundlage dieser Arbeit gegeben werden, bevor konkrete Ergebnisse diskutiert werden.

2 Theorie

2.1 Stand der Forschung

Der Beginn der Wissenschaftlichen auseinandersetzung mit Verschwörungstheorien wird üblicherweise rund um das Erscheinen von Richard Hofstadter und Wilentz (2008) Essay *The Paranoid Style in American Politics* verortet. In diesem setzt Hofstadter sich mit dem was er für von Verschwörungstheorien beeinflusste Politik in den USA hält, wie etwa die Schriften von Senator McCarthy und die nach ihm benannte Praxis des McCarthyismus .

Maybe citation needed

Das weitere Forschungsinteresse im restlichen 20. Jahrhundert hielt sich in Grenzen, die Verbleibende Forschung fiel meist in eine von Zwei Kategorien, wie Sunstein und Vermeule (2008) passend zusammenfassen:

The academic literature on conspiracy theories is thin, and most of it falls into one of two classes: (1) work by analytic philosophers, especially in epistemology and the philosophy of science, that asks what counts as a “conspiracy theory” and whether such theories are methodologically suspect; (2) a smattering of work in sociology and Freudian psychology on the causes of conspiracy theorizing. (Sunstein & Vermeule, 2008, S. 2)

In der jüngeren Vergangenheit haben vor allem Drei Entwicklungen Verschwörungstheorien oder zumindest deren Sichtbarkeit und damit auch der Forschung in diesem Bereich vorschub geleistet.

Dies wäre zum einen die Verbreitung des Internets um die Jahrtausendwende. Die Mehrheit der Autoren sieht hier darin ein erhebliches Hilfsmittel für die Verbreitung von Verschwörungstheorien, wie etwa Stano (2020) schreibt: “[...] The Internet, and in particular social networks, have proved fundamental to the spread and development of such [conspiracy] theories”(Stano, 2020, S. 492).¹

In der jüngsten Vergangenheit haben besonders die Wahl Donald Trumps zum US-Präsidenten 2016 und die aktuelle COVID-19 Pandemie Verschwörungstheorien ins öffentliche Interesse gerückt. Während die wissenschaftliche Aufarbeitung insbesondere von letzterer noch am Anfang steht, sind hier bereits erste Arbeiten vorhanden die neue Ansätze zeigen, wie etwa die von Shabsavari et al. (2020).

Eines der Kernprobleme der Forschungs zu Verschwörungstheorien, ist die Frage wie Verschwörungstheorien als solche zu identifizieren sind. Diese Frage hat nicht nur eine fundamentale Rolle für theoretische Arbeiten zu Verschwörungstheorien, sondern ist auch von immenser praktischer Relevanz in einer Zeit in der in sozialen Medien die Grenzen zwischen Nachrichten, Verschwörungstheorien und Fake-News immer schwerer auszumachen sind.

Eventuell google algorithmus zitieren

In der Vergangenheit war die wissenschaftliche Beantwortung dieser Frage meist eng mit der Frage danach verbunden was eine Verschwörungstheorie ausmacht und anhand welcher kriterien sich dies bestimmen lässt. Eine Beispielhafte

¹ Es gilt jedoch anzumerken, dass auch die gegenteilige Auffassung in der Literatur vertreten ist, so etwa bei Clarke (2007).

Arbeit ist hier Uscinski und Parent (2014). Die Autoren nutzen darin 6 verschiedene Tests um Verschwörungstheorien zu identifizieren, als Beispiel sei Occam's Razor, also die Frage nach der einfachsten Erklärung, und die falsifizierbarkeit einer Theorie genannt. Die Autoren selbst werten mit diesen Kriterien und der Methode der Inhaltsanalyse sowie einer Vielzahl von studentischen Kodierer:Innen einen Korpus an Briefen an US-Redaktionen aus (Uscinski & Parent, 2014, 54ff). Während die Autoren überzeugend dafür argumentieren, alle der aufgestellten Kriterien für eine Klassifizierung einzusetzen (Uscinski & Parent, 2014, 52f), ist keines der eingeführten Kriterien, zumindest mit den aktuellen technischen Möglichkeiten, wirklich geeignet um automatisierte Klassifikationen vorzunehmen.

Demgegenüber sind in jüngster Vergangenheit erste Arbeiten entstanden, die sich mit automatisierten Verfahren zum Erkennen von Verschwörungstheorien beschäftigen. Hier ist vor allem die Arbeit von Samory und Mitra (2018) hervorzuheben, in der die Autor:Innen automatisiert Triplets aus *agent*, *action* und *target* aus Verschwörungstheoretischen Online Beiträgen extrahieren. Als Datengrundlage nutzen sie dazu Beiträge aus dem Reddit Subforum r/conspiracy. Diese werten sie mittels einer NLP Pipeline aus die unter anderem Topic Modeling, Dependency Parser und Wordvektoren nutzt, aber auch vereinzelt Expertenwissen einbringt (Samory & Mitra, 2018, 6ff). Der Ansatz stellt einen wichtigen Beitrag zu einer vollständig automatisierten Analyse dar, ist aber auch verhältnismäßig komplex und basiert auf einer Datenbasis die nicht notwendigerweise Repräsentativ für "wild" vertretene Verschwörungstheorien ist, so dass die Übertragbarkeit für einen Identifizierungsmechanismus fragwürdig scheint.

Eine weitere Arbeit die sich mit automatisierten Auswertungen beschäftigt, ist die von Shavsavari et al. (2020). Die Autor:innen werten dabei Online Diskussionen in Foren wie Reddit und 4Chan aus, die sich mit der Covid 19 Pandemie beschäftigen. Die Auswahl ob Diskussionen verschwörungstheoretische Inhalte enthalten oder nicht, wurde dabei von einem Expertengremium getroffen (Shavsavari et al., 2020, 284f). Es werden mittels Methoden aus der Natürlichen Sprachverarbeitung narrative Netzwerke ausgewertet und so Verbindungen zu den Inhalten von Nachrichten und den aktuell "beliebtesten" Verschwörungstheorien aufgezeigt. Während auch diese Arbeit zweifelsfrei einen wichtigen Beitrag zu einem besseren Verständnis insbesondere der Verbreitung von Verschwörungstheorien in sozialen Netzwerken darstellt, wird das Problem der Identifizierung von Verschwörungstheorien damit nicht wirklich gelöst.

Hier eventuell
mehr/besser be-
legen/researchieren

2.2 Merkmale von verschwörungstheoretischen Texten

Um ebendiese Aufgabe angehen zu können, soll zunächst ein Blick in die Literatur erfolgen und in die in der qualitativen und quantitativen Forschung gemachten Beobachtungen zu sprachlichen Merkmalen von Verschwörungstheorien. Eine erschöpfende Auflistung aller in der Literatur zu findenden sprachlichen Merkmale von Verschwörungstheorien ist insbesondere mit dem erstarkten Forschungsinteresse in der jüngsten Vergangenheit kaum möglich noch wäre es

zielführend. Es sollen daher hier vor allem solche Merkmale genannt werden, die sich für eine quantitative Erfassung eignen und in dieser Arbeit

Eine in der Literatur häufig gemachte Beobachtung ist die emotionalität der Argumentation in Verschwörungstheorien (Vgl. Miller, 2002, S. 10). Dieses Argument findet sich auch bei Butter (2018, 93ff), der hier noch spezifischer darauf eingeht, dass es vor allem die vermeintlichen Verschwörer sind denen mit "metaphorisch aufgeladener, bisweilen apokalyptischer Sprache ausschließlich negative Eigenschaften zugeschrieben [werden]" (Butter, 2018, 93f).

Gleichzeitig spricht der Autor aber auch davon, dass sich Verschwörungstheoretiker traditionell um eine seriöse Darstellung bemühen und sich der verwendete Stil an den der Wissenschaft anlehne (Butter, 2018, S. 61). Diese Feststellung findet sich bereits bei Hofstadter und Wilentz (2008):

The higher paranoid scholarship is nothing if not coherent—in fact the paranoid mind is far more coherent than the real world. It is nothing if not scholarly in technique. McCarthy’s 96-page pamphlet, McCarthyism, contains no less than 313 footnote references, and Mr. Welch’s incredible assault on Eisenhower, The Politician, has one hundred pages of bibliography and notes. (Hofstadter & Wilentz, 2008, S. 37)

Seit der Erstveröffentlichung von Hofstadters Aufsatz hat vor allem die Existenz des Internets zu Veränderungen in der Erzählart von Verschwörungstheorien geführt. Die obsession an Belegen und Referenzen existiert zwar weiterhin, hat sich aber insoweit verändert, als das nicht mehr unbedingt Fussnoten das Mittel der Wahl sind, vielmehr werden Inhalte direkt eingebunden oder verlinkt. So schreibt etwa Soukup (2008) der sich spezifisch mit Verschwörungstheorien um den 11. September im Internet befasst, diese müssten als "digital, hypertextual, and multimedial experience" (Soukup, 2008, S. 10) verstanden werden.

Erst in der jüngeren Vergangenheit finden sich Arbeiten die sich spezifisch mit den linguistischen Merkmalen von Verschwörungstheorien auseinandersetzen. Schäfer (2018) etwa analysiert einen Korpus aus Kommentaren zu verschwörungstheoretischen YouTube-Videos. Sie stellt dabei unter anderem eine gehäufte Verwendung von Ironie und *scare quotes* fest, wenn es darum geht die Gegenseite negativ darzustellen (Schäfer, 2018, S. 235). Ähnlich der bereits erörterten Literatur findet die Autorin auch eine hohe Dichte von Belegen und Referenzen die die Kompetenzen der VerschwörungstheoretikerInnen unterstreichen sollen, stellt aber noch heraus, dass diese sich häufig durch nennen von Namen und Zahlenangaben ausdrücken (Schäfer, 2018, S. 234).

Eine ähnliche Beobachtung macht auch Filatkina (2018), welche feststellt:

In einem Beitrag oft mehrfach angeführte Verweise auf offizielle Zahlen [...] bzw. das wörtliche Zitieren der VertreterInnen der Wissenschaft und Politik sollen die Glaubwürdigkeit herstellen. (Filatkina, 2018, S. 208)

Ebenfalls stellt die Autorin fest, dass eine übliche Konstruktion darin besteht, durch offene und geschlossene Fragen die Aufmerksamkeit der LeserInnen auf bestimmte Aspekte zu lenken (Filatkina, 2018, S. 205).

Schlussendlich findet sich bei Römer und Stumpf (2019, S. 149) noch die Feststellung, dass häufig Negationswörter verwendet werden um die offiziellen Aussagen zu verneinen.

2.3 Textklassifizierung

3 Vorgehen

Der Arbeit zugrunde liegt ein Korpus aus Texten von Internetportalen, die der verschwörungstheoretischen, bzw. Truthther Szene zuzuordnen sind. Diese wurde im Verlauf der letzten Jahre über Webcrawling zusammengestellt. Eine genaue Beschreibung der Zusammensetzung des Korpus wird im weiteren Verlauf dieser Arbeit erfolgen.

Füllmüll?

Um eine strukturierte Analyse mit Methoden des maschinellen Lernens zu ermöglichen wird zunächst ein Vergleichskorpus mit Artikeln die von Form und Thematik möglich ähnlich den betrachteten, verschwörungstheoretischen Texten gelagert sind ohne aber die konspirativen Aspekte zu teilen.

Anschließend werden die kombinierten Korpora gereinigt und mit Verfahren aus der natürlichen Sprachverarbeitung Features extrahiert auf denen Klassifizierungsverfahren arbeiten können. Zum Einsatz kommen sollen dabei sowohl Features die klassischerweise für Textklassifikation herangezogen werden, wie etwa Wortfrequenzen, POS-Tags und Wortdichte [CITATION NEEDED] als auch Features die auf den Erkenntnissen qualitativer Forschung zu Verschwörungstheorien basieren.

Zitieren

Die häufig angesprochene Emotionalität (oder der Mangel an selbiger) [citations needed] von verschwörungstheoretischen Texten etwa soll durch eine Sentiment-Analyse betrachtet werden. Die häufig angesprochene Multimedialität/Fragmentiertheit von verschwörungstheoretischen Inhalten soll durch Analyse der eingebetteten Inhalte wie Bilder, Tweets und YouTube Videos aber auch über die Menge der Verlinkungen untersucht werden.

zitieren

Mit den so erstellten Daten soll abschließend ein Modell trainiert werden, dass zwischen den verschwörungstheoretischen Texten und dem Vergleichskorpus unterscheiden kann. Zum Einsatz kommen soll dazu *LightGBM* (Ke, 2019) eine Implementierung von Gradient Boosting Decision Trees [citation needed]. Dieses Verfahren bietet neben der relativ guten Präzision den Vorteil, dass die Ergebnisse ähnlich einfachen Entscheidungsbäumen verhältnismäßig gut interpretierbar sind, so lässt sich gut der Einfluss einzelner Features auf die Klassifizierung abschätzen.

4 Umsetzung

4.1 Datenbasis

R zitieren so nicht
schon geschehen

Als Grundlage dieser Arbeit wurde ein Korpus aus Texten von insgesamt 7 deutschsprachigen, der verschwörungstheoretiker Szene zuzurechnenden Internetangeboten erstellt. Die Skripte zum automatischen Abruf der Texte nutzen dafür das R-Paket *rvest* (Wickham, 2020) erstellt und extrahieren mittels für jede Seite separat erstellten CSS-Selektoren und XPATH-Querys den jeweiligen Artikeltext. In diesem Vorgang wurden noch kleinere Bereinigungen an den Texten vorgenommen um wiederkehrende, nicht zum Artikeltext gehörende Elemente wie Werbung oder Spendenaufrufe zu entfernen, die Texte selbst wurden jedoch soweit möglich nicht weiter bearbeitet. Weiterhin erfasst wurde zu den Artikeln das (angegebene) Veröffentlichungsdatum, der Artikeltitel sowie die Rubrik so diese Angabe vorhanden waren.




Abb. 1. Anzahl Artikel nach Veröffentlichungsdatum (nach Monat gruppiert)

Wirklich?

Der so erstellte Korpus umfasst insgesamt 16836 Texte und deckt beginnend in 2006 einen Zeitraum von 14 Jahren ab. Wie in Grafik 1 zu erkennen ist, steigt beginnend in 2016 die Zahl der Artikel im Korpus deutlich an. Dies liegt zum einen daran, dass einzelne der betrachteten Angebote die Veröffentlichungsfrequenz erhöht haben, ist aber überwiegend darauf zurückzuführen, dass nicht alle Internetangebote über den gesamten Zeitraum existiert haben sondern erst später aktiv wurden. Genauere Informationen zu den von den einzelnen Angeboten abgedeckten Zeiträumen sowie zu Artikelzahl und Länge finden sich in Tabelle 1.

Wie dort auch ersichtlich ist, unterscheidet sich nicht nur die absolute Zahl der Artikel nach Quelle stark, auch das Veröffentlichungsintervall schwankt von weniger als einem Artikel den Monat bis über 100. Es besteht weiterhin ein negativer Zusammenhang zwischen der Artikellänge und dem Veröffentlichungsintervall ($r = -0.72, p = 0.065$).

r richtiges Zeichen?

	Von	Bis	Mittlere Zeichenzahl	Anzahl Artikel	Ar- Artikel/Monat
Alles Schall und Rauch	23.08.2006	02.08.2020	5000	5349	32.0
conrebbi	05.09.2012	20.10.2014	5610	24	1.0
deutschlandpranger	29.10.2016	30.12.2020	7527	118	2.4
fm-tv	31.07.2008	02.11.2018	9158	97	0.8
hinterderfichte	16.01.2010	31.05.2018	4221	1083	10.8
recentr	03.08.2007	05.08.2020	5071	4762	30.5
Watergate.tv	20.05.2016	16.11.2020	2810	5403	101.9

Tabelle 1. Kennzahlen der einzelnen Quellen des Korpus

Auch eine inhaltliche Betrachtung zeigt deutliche Unterschiede zwischen den einzelnen Angeboten. So ist etwa *Alles Schall und Rauch (ASuR)* als ältestes vertretenes Angebot auch einer der "klassischsten" Vertreter des Genres. Hier wird der Nutzer direkt auf der Startseite mit Fragen konfrontiert wie "Was geschau wirklich am 11. September? oder "Was passiert tatsächlich mit dem Klima?" (Freeman, 2021).

Das muss anders

Die Seite bedient sich klassischer Verschwörungstheorien und wird im allgemeinen der Truthther Szene zugeordnet („Alles Schall und Rauch“, 2020). Sie hat laut eigenaussage im Schnitt über 50.000 Zugriffe täglich².

Eventuell zitation zu häufigen fragen.

Inhaltlich finden sich sowohl Essay-artige Artikel zu Themen wie 9/11, Bilderberger oder Klimawandel auf der Seite, als auch kürzer gehaltene Meldungen zu aktuellen Ereignissen. Es werden, wie bei fast allen anderen Seiten im Korpus, häufig Inhalte Dritter eingebunden sowie die Artikel durch Bilder oder Grafiken ergänzt.

Ähnlich gelagert sind die Angebote *Hinter der Fichte (HdF)* und *conrebbi*, beide können der Truthther Szene zugerechnet werden (siehe etwa „Conrebbi“, 2020). In beiden Angeboten werden aktuelle Ereignisse kommentiert und verschwörungstheoretisch interpretiert, sowie längere Essays zu typischen Themen verfasst. Im Vergleich zu *ASuR* werden bei beiden Angeboten deutlich mehr Inhalte in Form von Videos und Fremdquellen in Bild und Textform genutzt.

Etwas aus der Reihe fallen die Angebote *fm-tv* sowie *Deutschlandpranger*. Inhaltlich finden sich etwa beim *Deutschlandpranger* recht klassische Themen

² Der Besucherzähler der Website ist inzwischen nicht mehr funktional, Angabe übernommen aus (Anonymous, 2020)

wie die Leugnung des Klimawandels (vgl. 2020), sind die dazugehörigen Text überdurchschnittlich lang und voller Werbung für Bücher zu z.T. komplett unabhängigen Themen. Auch sind die Texte selbst teilweise relativ wirr, so enthalten beispielsweise die (sehr ausführlichen) AGB einen Abschnitt zu Strafzahlungen bei "Übersenden eines Statements anstatt einer echten Rechnung (True Bill) des wahren Haftungsgläubigers"(2016).

Die verbleibenden beiden Angebote *recentr* und *Watergate.tv* sind beide der rechten Szene zuzuordnen und verbreiten Verschwörungstheorien in diese Richtung. Beide zeichnet ein eher journalistischer Stil aus, es werden kurze bis mittellange Meldungen veröffentlicht, häufig begleitet von eigenen oder fremden Videos. *Recentr* wurde 2006 als deutscher Ableger von *Inforwars.com* gegründet und bedient sich noch heute einem ähnlichen Konzept. Ähnlich dem Vorbild wird massiv Werbung für den eigenen Shop gemacht in dem diverse Produkte zur Vorbereitung auf apokalyptische Szenarien sowie fragwürdige Nahrungsergänzungsmittel verkauft werden. Inhaltlich ist vor allem interessant, dass sich die Seite (bzw. der Hauptautor Alexander Benesch) z.T. sehr explizit von anderen Teilen der rechten/verschwörungstheoretischen Szene abgrenzt.³ So kommt es durchaus vor, dass in einem Artikel zunächst von der implausiblen Sichtweise, verschiedenste Regierungen hätten eine Fake-Pandemie orchestriert"(Benesch, 2021a) gesprochen wird, nur um im nächsten Satz zu erklären:

In Wirklichkeit sind die Methoden der globalen Bevölkerungsreduktion fast ausschließlich legal, simpel und werden schrittweise angewandt [...]. Das Konzept ist so entworfen, um mit möglichst wenig Zwang auszukommen [...]. (Benesch, 2021a)

Die Website *Watergate.tv* (inzwischen Teil von *NEOPresse.com*) ist ein rechtslastiges Nachrichten und Videoportal, das sich verschwörungstheoretischer Narrative bedient. Auf dem Portal finden sich klassische Themen wie Bilderberger (vgl. Redaktion, 2018) aber auch Fake-News und Berichterstattung mit starker pro-russischen Tendenz. In die Öffentlichkeit rückte das Portal als sich das Neo-Magazin-Royale wegen seiner Mitarbeit bei *Watergate.tv* von Hans Meiser trennte (Siehe z.B. 2017).

Kurzes Fazit Korpus

Bei der Erstellung des Vergleichskorpus war es das Ziel Quellen zu wählen die dem Korpus konspirativer Texte möglichst ähnlich sind, ohne die konspirativen Aspekte zu enthalten. Da insbesondere die letzten beiden besprochenen Angebote sich inhaltlich sehr an journalistische Angebote anlehnen, lag es nah ebensolche heranzuziehen. Aus Gründen der Vollständigkeit (Die Angebote sollten möglichst den kompletten Zeitraum des Korpus abdecken) sowie der Zugänglichkeit wurden die Angebote von Spiegel Online sowie der Frankfurter Rundschau ausgewählt. Es wurde für beide Onlineangebote zunächst ein Index aller Artikel die in den selben Zeitraum wie der Korpus fallen erstellt und aus diesem zufällig eine Auswahl von 10000 Artikeln pro Anbieter gezogen.

³ So grenzt sich das Portal in Beiträgen inzwischen auch von *Inforwars* Gründer Alex Jones ab (2018) oder spekuliert darüber, ob die Alternative für Deutschland vom britischen Geheimdienst gegründet wurde (Benesch, 2021b)

Die restlichen im Korpus enthaltenen Seiten sind alle mehr oder weniger in Blogform gehalten. Um Inhalte in einer vergleichbaren Form zu finden aber auch dem in der Literatur häufig anzutreffenden Feststellungen der wissenschaftlichen Form von verschwörungstheoretischen Texten Rechnung zu tragen wurde eine Reihe von Wissenschaftsblogs als zweite Komponente im Vergleichskorpus gewählt. Dafür wurden von den beiden Plattformen scienceblogs und scilogs⁴ ähnlich den journalistischen Angeboten aus dem gesamten Index der Einträge eine Auswahl von jeweils 10000 Artikeln ausgewählt. Genauere Kennwerte zum Vergleichskorpus siehe in Tabelle 2.

	Von	Bis	Mittlere Zei- chenzahl	Anzahl Artikel	Artikel/Monat
Frankfurter Rundschau	03.08.2006	04.08.2020	3670	9959	59.3
scienceblogs	14.02.2007	04.08.2020	3261	8765	54.4
scilogs	29.12.2000	03.08.2020	5206	9533	40.6
Spiegel online	On- 01.08.2006	07.01.2020	4687	8665	53.8

Tabelle 2. Kennzahlen der einzelnen Quellen des Vergleichskorpus

4.2 Datenvorverarbeitung

Zunächst wurden einige Säuberungsschritte auf den Korpus angewendet, um zu verhindern, dass fehlerhafte oder irrelevante Daten mit für die Feature Erstellung herangezogen werden.

Es wurde zunächst Unicode Normalisierung für alle Texte durchgeführt, anschließend wurden mittels des *Google Compact Language Detector 3* (Ooms, 2021) die Sprache aller Text bestimmt nur (überwiegend) deutschsprachige Texte zu betrachten. Da im Korpus an einigen Stellen noch nicht zum Artikeltext gehörige Komponenten aus vielen Sonderzeichen vorhanden waren, wurden alle Wörter entfernt, die nur aus Zeichen bestanden, die unter 1000 Mal im gesamten Korpus vorkamen. Schlussendlich wurden noch kleinere Korrekturen vorgenommen, wie das Zusammenfassen multipler, aufeinanderfolgender Leerzeichen und Unterstriche (die gerne als Trennlinien in den Text benutzt wurden).

Schlussendlich wurden noch alle Text unter 100 Zeichen Länge aus dem Korpus entfernt, da diese für die Klassifizierungsaufgabe nur wenig Informationen enthalten können. Der finale Korpus umfasste 53758 Texte, mit einem Anteil der positiven Klasse (sprich von verschwörungstheoretischen Texten) von etwa 32%.

⁴ Beide Plattformen sind Anbieter bei denen eine Vielzahl verschiedener Blogs zu finden sind.

4.3 Features

Zitation allgemein
sentimentanalyse

Basierend auf den Erkenntnissen der bisherigen Forschung zu verschwörungstheoretischen Texten wurden Features für die verwendeten Klassifikationsverfahren erstellt. Während in der Forschung kein klarer Konsens besteht ob Verschwörungstheorien besonders emotional [CITATION NEEDED] oder besonders sachlich [CITATION NEEDED] Argumentieren, scheint die Emotionalität allgemein ein wichtiger Aspekt zu sein. Um dies zu operationalisieren wurden das Sentimentwörterbuch *SentiWS* (Remus et al., 2010) genutzt. Dieses umfasst positive und negative Sentimentwerte für über 3000 Grundformen deutscher Wörter. Während komplexere Ansätze wie etwa der von (2013) eine höhere Präzision versprechen,⁵ scheint die genutzte Methode für den vorliegenden Kontext ausreichende Ergebnisse zu liefern. Es wurde die Summe der positiven und negativen Sentimente erfasst, also auch die Gesamtsumme sowie der Betrag nach Text. Hiermit soll insbesondere auf solche Fälle eingegangen werden, in denen ein Text zwar viele emotional behaftete Wörter verwendet, sich die Sentimentsumme aber durch einen Wechsel an positiven und negativen Wörtern ausgleicht.

Ein weiteres Merkmal das in der Literatur häufig anzutreffen ist [CITATION NEEDED] ist die hohe Menge an Zitaten. Um diese nutzen zu können wurden zum einen die Anzahl der Anführungszeichen im Text gezählt. Eine genauere Betrachtung wird ermöglicht da auch die Zahl der Zitationen ohne Zitate im Zitat sowie die durchschnittliche Länge von Zitaten und deren Anteil am Gesamttext erfasst wird. Ebenfalls wird die Anzahl an Scare-Quotes erfasst, wobei Scare-Quotes hier definiert sind als ein Zitat in dem keine Leerzeichen enthalten sind.

Die häufig anzutreffende Beobachtung, dass Verschwörungstheoretische Texte häufig viele Fragen stellen [CITATION NEEDED] wird durch ein simples Zählen der Fragezeichen abgedeckt. Ähnlich lässt sich auch die Annahme über die Häufung von Zahlenangaben [CITATION NEEDED] durch einfaches Zählen von Zahlengruppen abbilden. Ebenfalls wird in der Literatur davon gesprochen, dass verschwörungstheoretische Texte häufig negationen verwenden. Um dies Informationen nutzbar zu machen wurde händisch eine Liste von 15 Negationswörtern erstellt und deren Häufigkeit in den Texten gemessen. Alle Features wurden mit der Textlänge skaliert.

Ein weitere häufig anzutreffende Beobachtung zu Verschwörungstheoretischen Texten spezifisch im Internet ist deren Multimedialität sowie deren Verknüpftheit untereinander. [CITATIONS NEEDED EN MASSE] Um diese Eigenschaften abzubilden wurden eine Reihe von Informationen aus den Hypertext Dateien extrahiert aus denen die Texte stammen. Um die Multimedialität zu erfassen wurde die Anzahl der eingebundenen Bilder, Tweets, Youtube-Videos sowie anderer eingebetteter Elemente im Artikel gezählt. Die Verknüpftheit wurde über die Anzahl von Links im Artikel, aufgeteilt nach internen und externen Links, erfasst. Ebenso wurde die Menge an fettgedruckten und kursiven Text erfasst.

Um neben den in der Literatur zu findenden Merkmalen auch eine weitergehende Untersuchung der Texte zu ermöglichen wurden weiterhin auch Features

⁵ So ist der hier vorgestellte Ansatz nicht in der Lage mit negationen umzugehen.

die häufig im Bereich der Textklassifikation genutzt werden mit einbezogen. Dazu wurde der Corpus zunächst mithilfe von *spaCy* (Honnibal et al., 2020) annotiert. Es wurden anschließend der Anteil jedes Part-of-Speech Tags als Feature übernommen, sowie der Anteil an großgeschriebenen Text und Sonderzeichen. Ebenso wurde die Wortdichte für jeden Text bestimmt, also die Anzahl an Wörtern im Verhältniss zur Textlänge. Zur ermittlung von Wortfrequenzen wurden zunächst Stopwörter aus dem Corpus gefiltert⁶, die Wörter auf die Lemmata reduziert, einige Sonderfälle aussortiert⁷ und anschließend die 400 häufigsten Wörter als Features übernommen.

4.4 Modellerstellung

Für die Modellerstellung kam die LightGBM (Ke, 2019) Bibliothek zum Einsatz. Zum Hyperparamethertuning wurde ein bayesscher Optimierer aus dem Paket *ParBayesianOptimization* (Wilson, 2021) genutzt.

Zunächst wurde ein Model erstellt, dass sich auf Features die auf in der Literatur zu findenden Beobachtungen basieren. Dafür wurde ein Train/Validate Split im Verhältniss 2:1 vorgenommen. Auf den Trainingsdaten wurde mittels in lightgbm vorhandener Funktionalität über eine 10-Fold Kreuzvalidierung die optimale Anzahl an Booster Iterationen ermittelt um ein Overfitting der Daten zu verhindern, welches eines der Hauptprobleme bei Gradientenbossting Methoden ist. Das anschließend mit dieser Bassis trainierte Model erreichte auf dem Validation Set eine Präzision von 78.5%. [NEEDED: MEHR DATEN]

[HERE BE HYPERPARAMTER TABLE]

Anschließend wurde ein Modell mit allen 462 Features erstellt. Hier wurde ebenfalls mittels Kreuzvalidierung die optimale Iterationstiefe bestimmt, die Validierung des anschließend erstellten Modells erfolgte aber mittels einer 10-Fachen Kreuzvalidierung auf den gesamten Trainingsdaten. Die dafür verwendeten Parameter sind Tabelle [TABELLE] zu entnehmen. Das so trainierte Modell erreichte eine Präzision von 97.86%.

⁶ Zum Einsatz kam die Stopwort Liste aus dem *tm* Paket (Feinerer et al., 2008)

⁷ So wurde beispielsweise das Wort dpa nicht übernommen, da es praktisch exklusiv in Artikeln von Frankfurter Rundschau und Spiegel Online vorkommt.

14 Fuhry

5 Ergebnisse

6 Fazit

Literatur

- Butter, M. (2018). *Nichts ist, wie es scheint: über Verschwörungstheorien* (Originalausgabe, Erste Auflage). Suhrkamp.
- Clarke, S. (2007). Conspiracy Theories and the Internet: Controlled Demolition and Arrested Development. *Episteme*, 4(2), 167–180. <https://doi.org/10.3366/epi.2007.4.2.167>
- Filatkina, N. (2018). Der Anfang vom Ende Europas. Verschwörungstheoretisches Sprechen im Migrationsdiskurs (D. Römer & S. Stumpf, Hrsg.). *aptum*, 3 (2018), 197–220.
- Hofstadter, R. & Wilentz, S. (2008). *The Paranoid Style in American Politics*. Random House. <https://books.google.de/books?id=XcLSoljnmBcC>
- Miller, S. (2002). Conspiracy Theories: Public Arguments as Coded Social Critiques: a Rhetorical Analysis of the Twa Flight 800 Conspiracy Theories. *Argumentation and Advocacy*, 39(1), 40–56. <https://doi.org/10.1080/00028533.2002.11821576>
- Neethu, M. S. & Rajasree, R. (2013). Sentiment analysis in twitter using machine learning techniques. *2013 Fourth International Conference on Computing, Communications and Networking Technologies (ICCCNT)*, 1–5. <https://doi.org/10.1109/ICCCNT.2013.6726818>
- Remus, R., Quasthoff, U. & Heyer, G. (2010). SentiWS - A Publicly Available German-language Resource for Sentiment Analysis. *Proceedings of the Seventh International Conference on Language Resources and Evaluation (LREC'10)*. http://www.lrec-conf.org/proceedings/lrec2010/pdf/490_Paper.pdf
- Römer, D. & Stumpf, S. (2019). Populismus und Verschwörungstheorien aus linguistischer Perspektive (D. Römer & C. Spieß, Hrsg.). *Osnabrücker Beiträge zur Sprachtheorie*, 95, 129–158.
- Schäfer, P. (2018). Verschwörungstheorien – Ein Fall für die linguistische Vertrauensforschung (D. Römer & S. Stumpf, Hrsg.). *Aptum*, 3 (2018), 221–238.
- Shahsavari, S., Holur, P., Wang, T., Tangherlini, T. R. & Roychowdhury, V. (2020). Conspiracy in the time of corona: automatic detection of emerging COVID-19 conspiracy theories in social media and the news. *Journal of Computational Social Science*, 3(2), 279–317. <https://doi.org/10.1007/s42001-020-00086-5>
- Soukup, C. (2008). 9/11 conspiracy theories on the World Wide Web: Digital rhetoric and alternative epistemology. *Journal of Literacy and Technology*, 9(3), 2–25.
- Stano, S. (2020). THE INTERNET AND THE SPREAD OF CONSPIRACY CONTENT. In M. Butter & P. Knight (Hrsg.), *Routledge Handbook of Conspiracy Theories* (S. 483–496). Routledge.
- Sunstein, C. R. & Vermeule, A. (2008). Conspiracy Theories. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.1084585>
- Uscinski, J. E. & Parent, J. M. (2014). *American Conspiracy Theories*. Oxford University Press.

Software

- Feinerer, I., Hornik, K. & Meyer, D. (2008). Text Mining Infrastructure in R. *Journal of Statistical Software*, 25(5), 1–54. <https://www.jstatsoft.org/v25/i05/>
- Honnibal, M., Montani, I., Van Landeghem, S. & Boyd, A. (2020). *spaCy: Industrial-strength Natural Language Processing in Python*. Zenodo. <https://doi.org/10.5281/zenodo.1212303>
- Ke, G. (2019). *lightgbm: Light Gradient Boosting Machine* [R package version 2.3.2]. <https://github.com/Microsoft/LightGBM>
- Ooms, J. (2021). *cld3: Google's Compact Language Detector 3* [R package version 1.4.1]. <https://CRAN.R-project.org/package=cld3>
- Wickham, H. (2020). *rvest: Easily Harvest (Scrape) Web Pages* [R package version 0.3.6]. <https://CRAN.R-project.org/package=rvest>
- Wilson, S. (2021). *ParBayesianOptimization: Parallel Bayesian Optimization of Hyperparameters* [R package version 1.2.4]. <https://CRAN.R-project.org/package=ParBayesianOptimization>

Online

- Alles Schall und Rauch. (2020). Psiram. Verfügbar 23. Mai 2021 unter https://www.psiram.com/de/index.php/Alles_Schall_und_Rauch
- Anonymous. (2020). *Mein Vater ist der Verschwörungstheoretiker hinter Alles Schall und Rauch*. Vice. Verfügbar 23. Mai 2021 unter <https://www.vice.com/de/article/gyx8aq/mein-vater-der-bekannte-verschwörungstheoretiker>
- Benesch, A. (2018). *Alex Jones: Internierungslager und REX-84 sind jetzt die Rettung Amerikas*. Recentr. Verfügbar 23. Mai 2021 unter <http://recontr.com/2018/06/26/alex-jones-internierungslager-und-rex-84-sind-jetzt-die-rettung-amerikas/>
- Benesch, A. (2021a). *Bevölkerungsreduktion wird schrittweise, mit fast ausschließlich legalen Mitteln betrieben, anders als viele sich das vorstellen*. Recentr. Verfügbar 23. Mai 2021 unter <http://recontr.com/2021/05/10/bevoelkerungsreduktion-wird-schrittweise-mit-fast-ausschliesslich-legalen-mitteln-betrieben-anders-als-viele-sich-das-vorstellen/>
- Benesch, A. (2021b). *Ist die AfD eine britische Schöpfung?* Recentr. Verfügbar 23. Mai 2021 unter <http://recontr.com/2021/06/29/ist-die-afd-eine-britische-schoepfung/>
- Blog AGB's. (2016). Deutschland - Pranger. Verfügbar 23. Mai 2021 unter <http://deutschland-pranger.de/b2evolution/index.php/ueber-diese-seite>
- Conrebbi. (2020). Psiram. Verfügbar 23. Mai 2021 unter <https://www.psiram.com/de/index.php/Conrebbi>
- Conrebbi. (2020). Psiram. Verfügbar 23. Mai 2021 unter <https://www.psiram.com/de/index.php/Conrebbi>
- Freeman. (2021). *Homepage*. Verfügbar 23. Mai 2021 unter <http://alles-schallundrauch.blogspot.com/>

- Redaktion, W. (2018). *+++ Schulz tritt sofort zurück – Bilderberger Scholz gibt jetzt den Ton an +++*. Watergate.tv. Verfügbar 23. Mai 2021 unter <https://wg.neopresse.com/schulz-tritt-sofort-zurueck-bilderberger-scholz-gibt-jetzt-den-ton-an/>
- ZDF bestätigt Trennung von Hans Meiser. (2017). Spiegel Online. Verfügbar 23. Mai 2021 unter <https://www.spiegel.de/kultur/tv/jan-boehmermann-neo-magazin-royale-kuenftig-ohne-hans-meiser-a-1148048.html>